PROYECTO: NASA EXOPLANETAS

Predicción del método de detección de exoplanetas

Equipo compuesto por:
Carmen Gómez
Neha Malhotra
Marta Estévez

De datos a decisión: priorización y análisis de sesgos

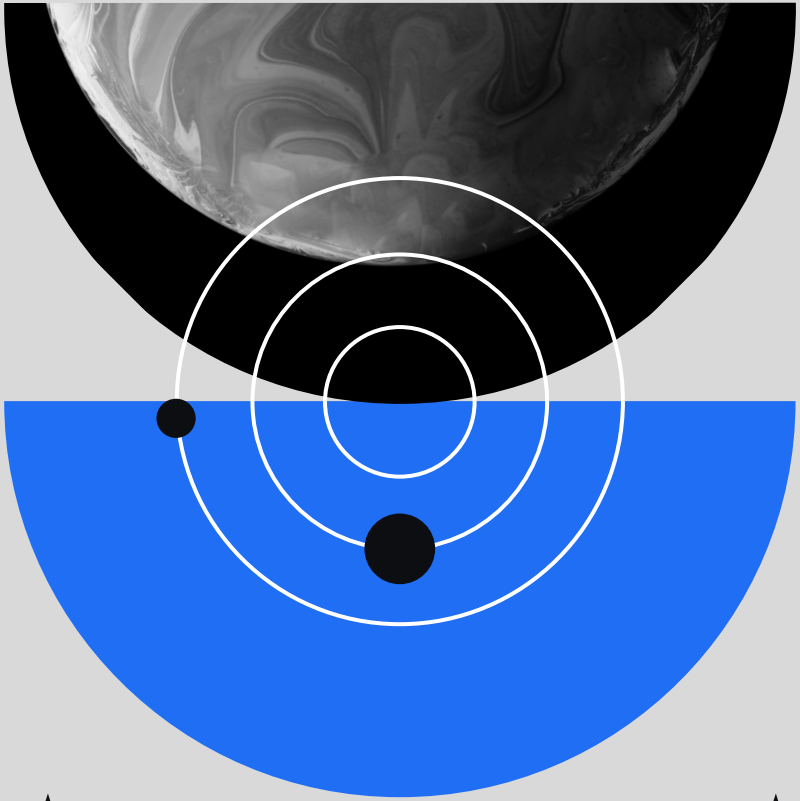

01

El problema de negocio

El problema de negocio

- **Reto:** recursos de observación limitados (tiempo/instrumentos)
- **Necesidad:** priorizar candidatos y técnica de detección
- **Pregunta:** “¿Qué método es más probable para este candidato?”

Candidatos / catálogo

Modelo

Método recomendado + confianza

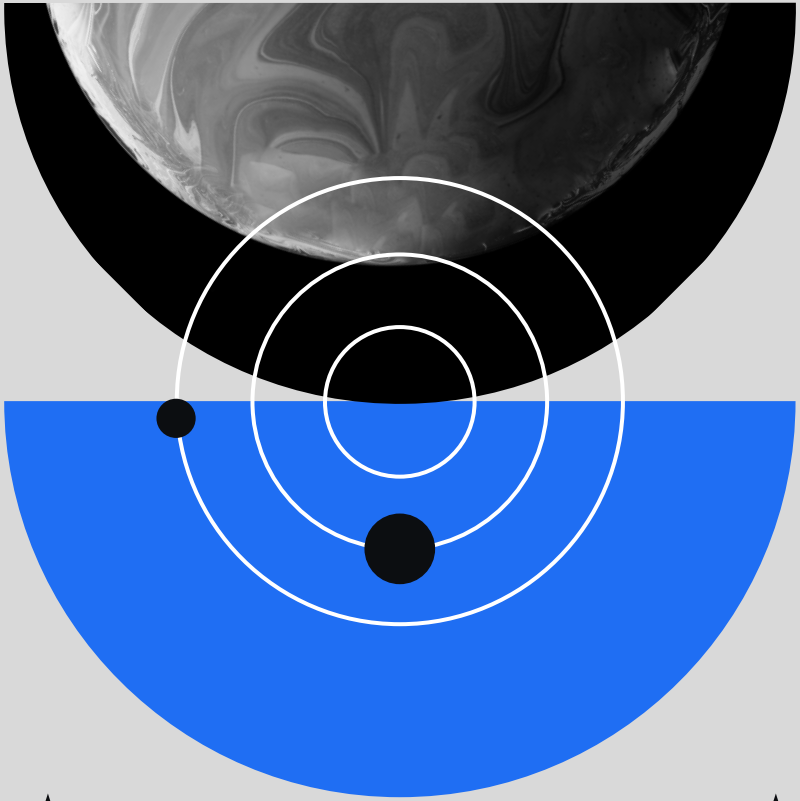

02

Objetivo y enfoque técnico

Objetivo y enfoque técnico

- ➔ **Objetivo:** predecir *detection_method*
- ➔ **Tipo de problema:** clasificación supervisada multiclase
- ➔ **Métrica principal:** F1-macro (por desbalanceo)

PROCESO:

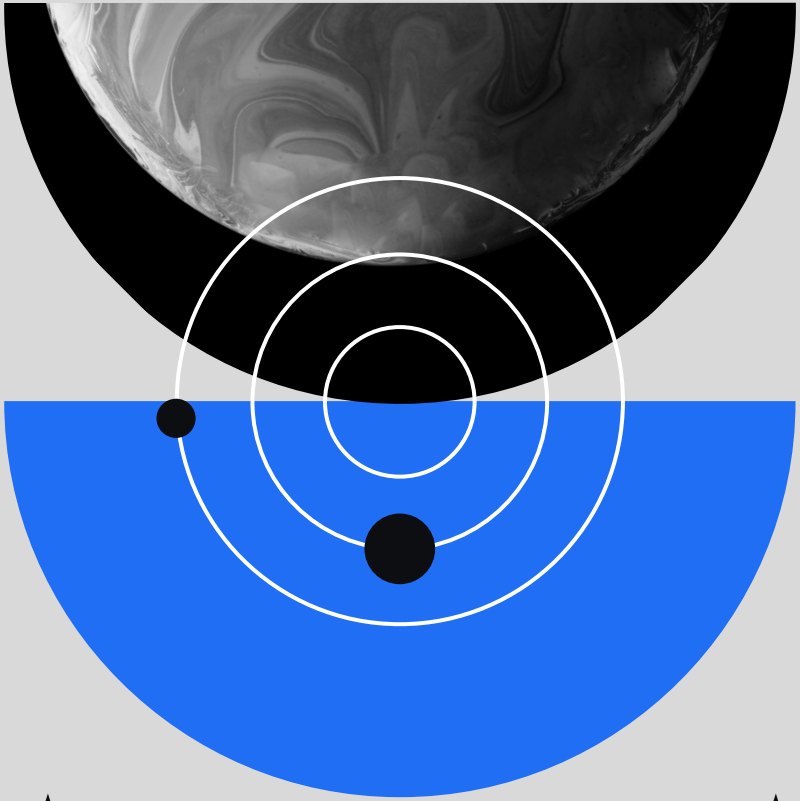

03

Dataset y preparación inicial

Objetivo y enfoque técnico

- ➔ **Fuente:** NASA Exoplanets (Kaggle)
- ➔ **Tamaño:** 5250 filas, 13 columnas
- ➔ **Variables:** masa/radio/periodo/excentricidad/distancia/magnitud estelar…
- ➔ **Limpieza:** vacíos→NaN, duplicados, missing

	name	distance	stellar_magnitude	planet_type	discovery_year	mass_multiplier	mass_wrt	radius_multiplier	radius_wrt	orbital_radius	orbital_period	eccentricity	detection_method
0	11 Comae Berenices b	304.0	4.72307	Gas Giant	2007	19.40000	Jupiter	1.08	Jupiter	1.290000	0.892539	0.23	Radial Velocity
1	11 Ursae Minoris b	409.0	5.01300	Gas Giant	2009	14.74000	Jupiter	1.09	Jupiter	1.530000	1.400000	0.08	Radial Velocity
2	14 Andromedae b	246.0	5.23133	Gas Giant	2008	4.80000	Jupiter	1.15	Jupiter	0.830000	0.508693	0.00	Radial Velocity
3	14 Herculis b	58.0	6.61935	Gas Giant	2002	8.13881	Jupiter	1.12	Jupiter	2.773069	4.800000	0.37	Radial Velocity
4	16 Cygni B b	69.0	6.21500	Gas Giant	1996	1.78000	Jupiter	1.20	Jupiter	1.660000	2.200000	0.68	Radial Velocity

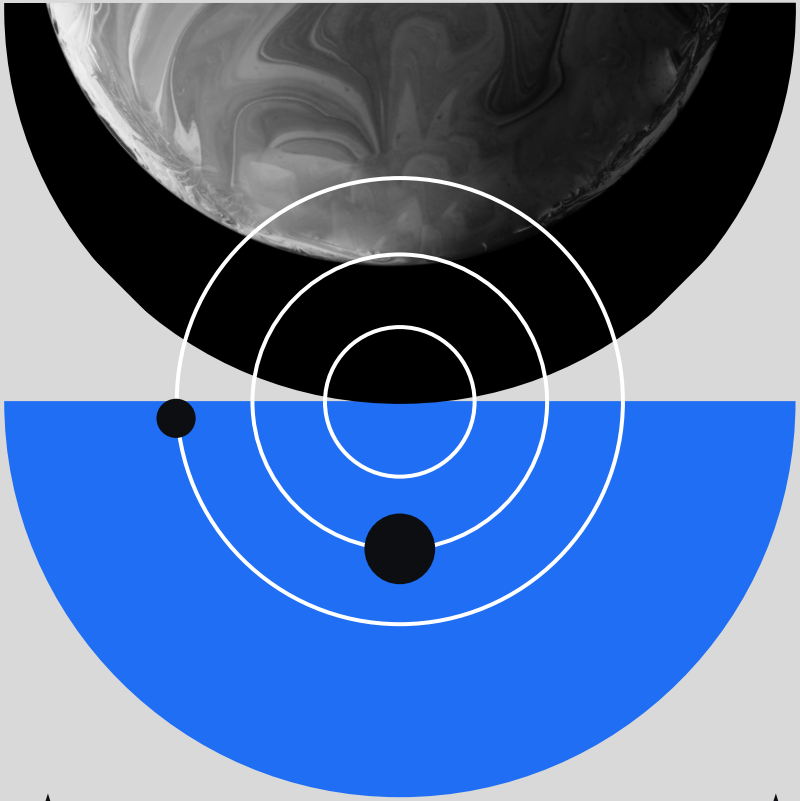

04

EDA: hallazgos clave

EDA: hallazgos clave

- ➔ **Missing bajos** (máximo ~5.5% en orbital_radius)
- ➔ **Target desbalanceado:** Transit domina
- ➔ **Outliers presentes en algunas numéricas** → revisión/tratamiento

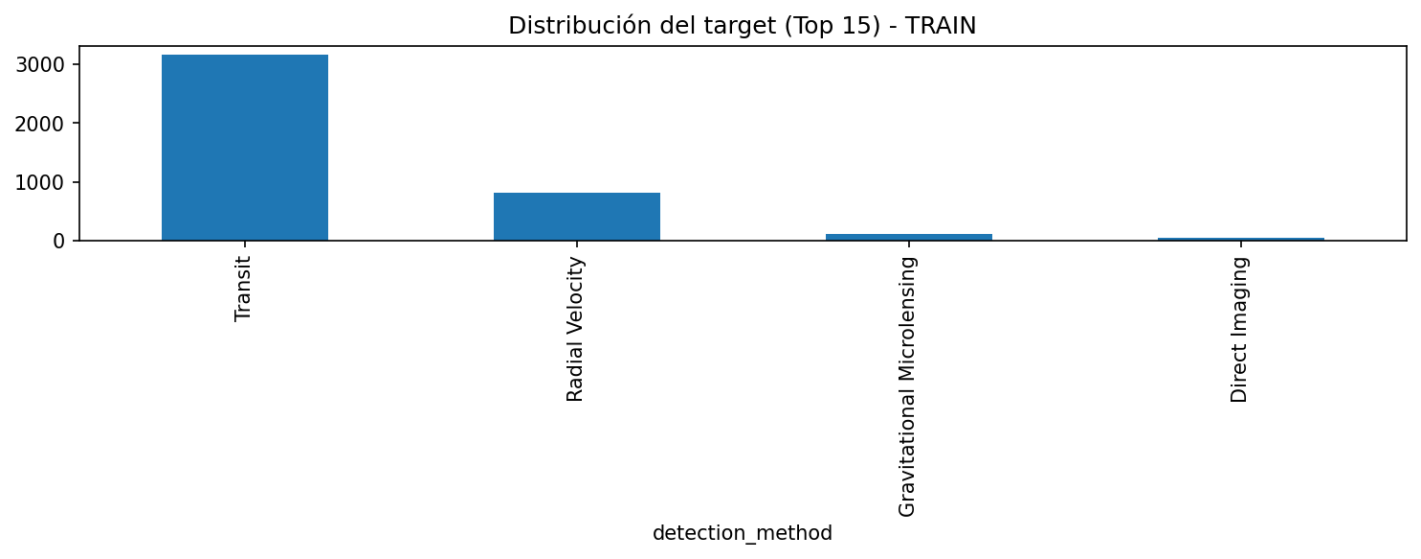

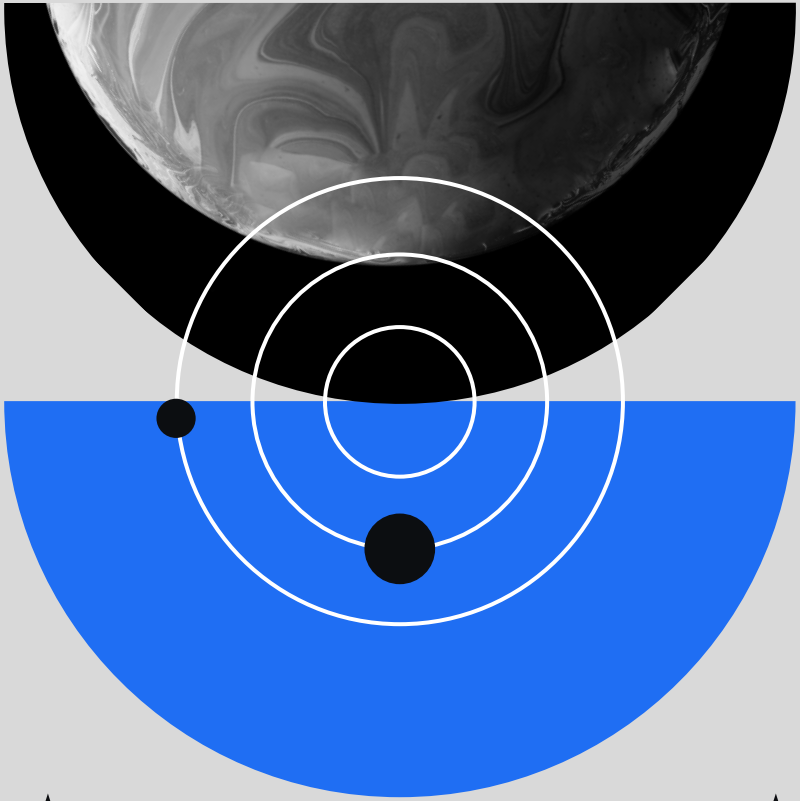

05

Preprocesado y reducción de variables

Preprocesado y reducción de variables

- **Reducción preliminar:** constantes / ID-like / alta cardinalidad. Columna name eliminada
- **Pipeline:**
  - **Numéricas:** mediana + escalado
  - **Categóricas:** moda + one-hot
- **Outliers:** clipping IQR

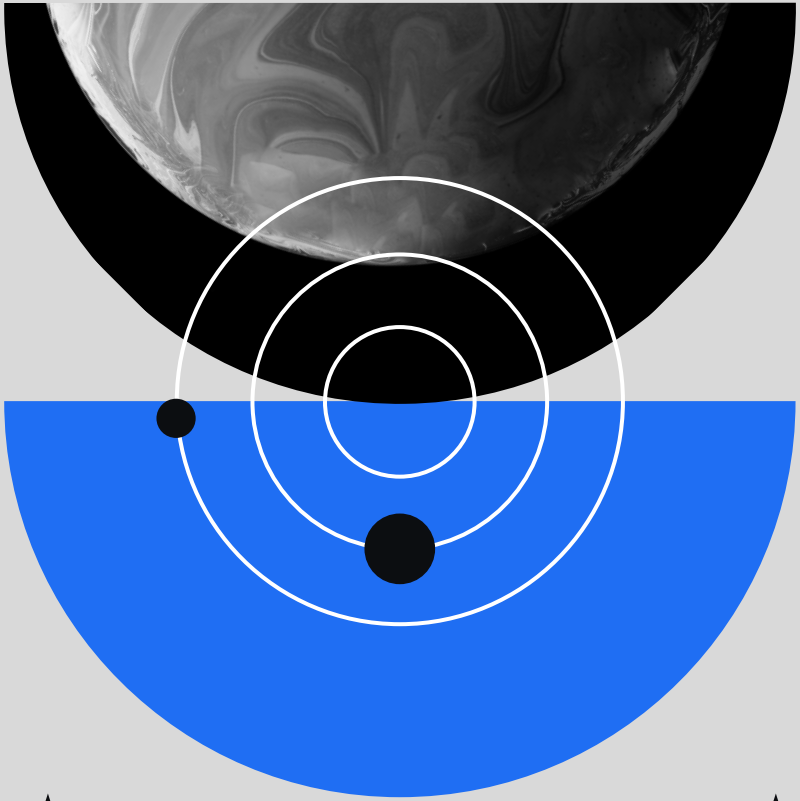

06

Modelado

Modelado: Comparación de modelos

model	f1_macro	accuracy
RF	0.927572	0.974217
GBC	0.925489	0.975663
LogReg	0.856081	0.948193
Dummy	0.215987	0.760482

Comparamos modelos con 5-fold CV

- ➔ **Modelos:** Dummy, LogReg, RF, GBC
- ➔ **Métrica:** F1-macro + accuracy

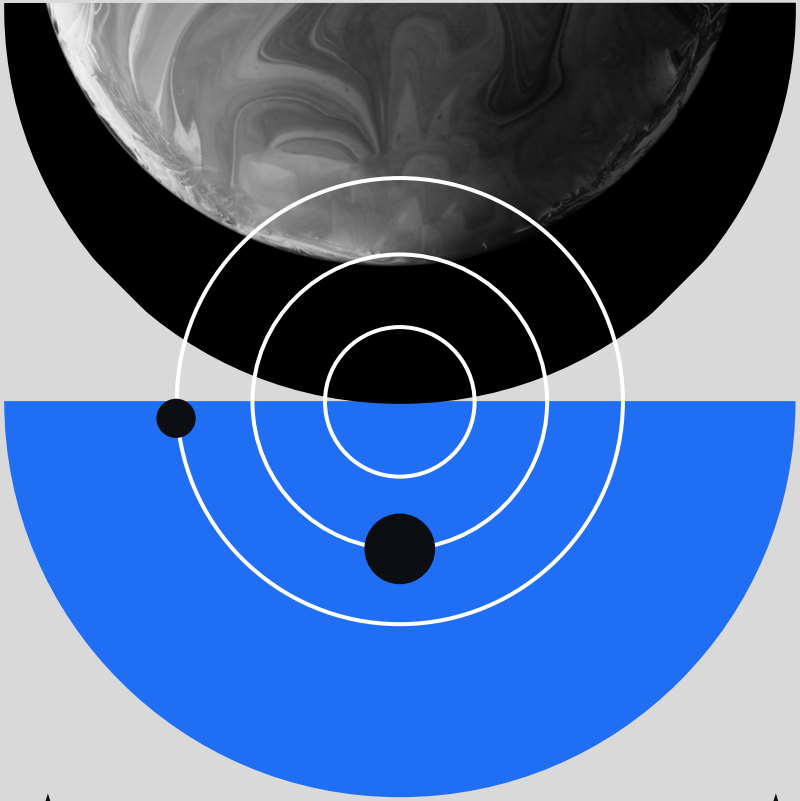

07

Tuning + evaluación

Tuning + evaluación

- **Tuning:** RandomizedSearchCV (CV 5-fold)
- **Mejor modelo:** Random Forest
- **Mejores hiperparámetros:** n_estimators=900, max_depth=10, min_samples_split=2
- **Resultado en test:**
  - **Accuracy ~0.98**
  - **Macro F1 ~0.96**

Tuning + evaluación

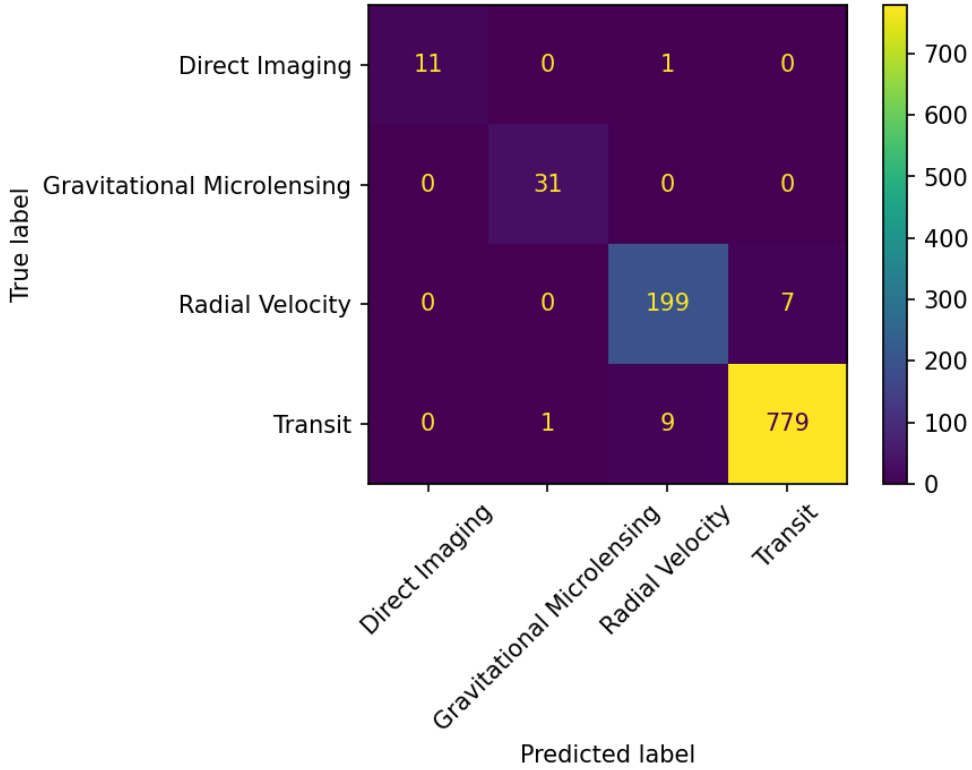

- ➔ **Muy buen rendimiento en clases mayoritarias (Transit/RV)**
- ➔ **Errores en minoritarias (Direct Imaging)**
- ➔ **Mejora enfocada:** balanceo y datos/estrategias para minoritarias

```
=== TEST report ===
                          precision    recall  f1-score   support

            Direct Imaging       1.00      0.92      0.96        12
Gravitational Microlensing       0.97      1.00      0.98        31
            Radial Velocity       0.95      0.97      0.96       206
                   Transit       0.99      0.99      0.99       789

                  accuracy                           0.98      1038
                 macro avg       0.98      0.97      0.97      1038
              weighted avg       0.98      0.98      0.98      1038
```

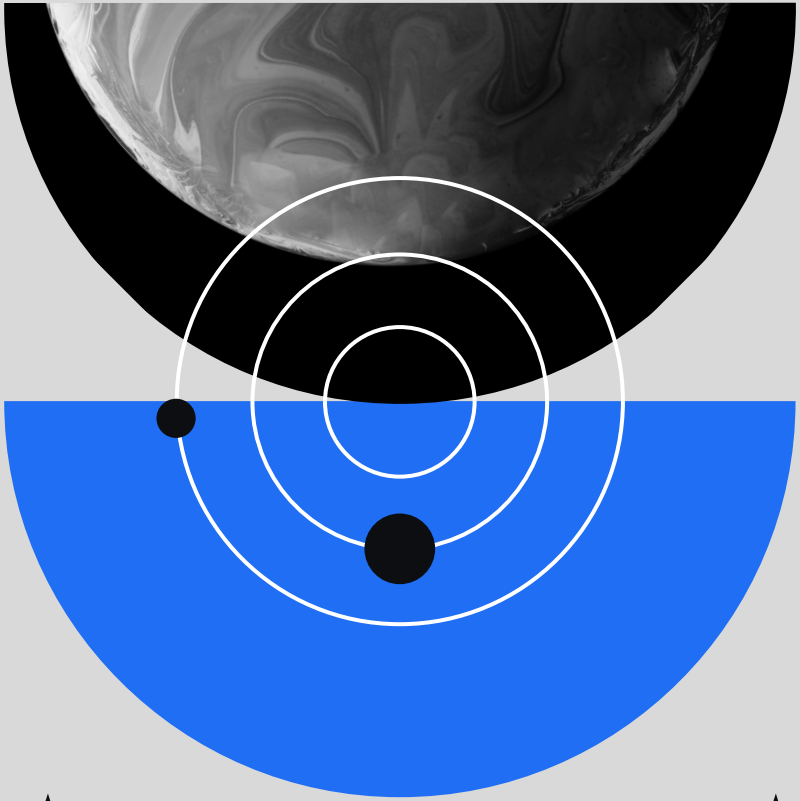

08

Conclusiones

Conclusiones:

- El método de detección es altamente predecible con estas variables.
- Pipeline reproducible + evaluación robusta (CV + test)

Acciones concretas:

➔ Rebalanceo: class_weight + oversampling solo en train
➔ Calibración de probabilidades para scoring de confianza
➔ Interpretabilidad (importancia/SHAP) para explicar recomendaciones
➔ Validación temporal por año (robustez y drift)
➔ Versión operativa: entrenar solo con variables disponibles antes del descubrimiento

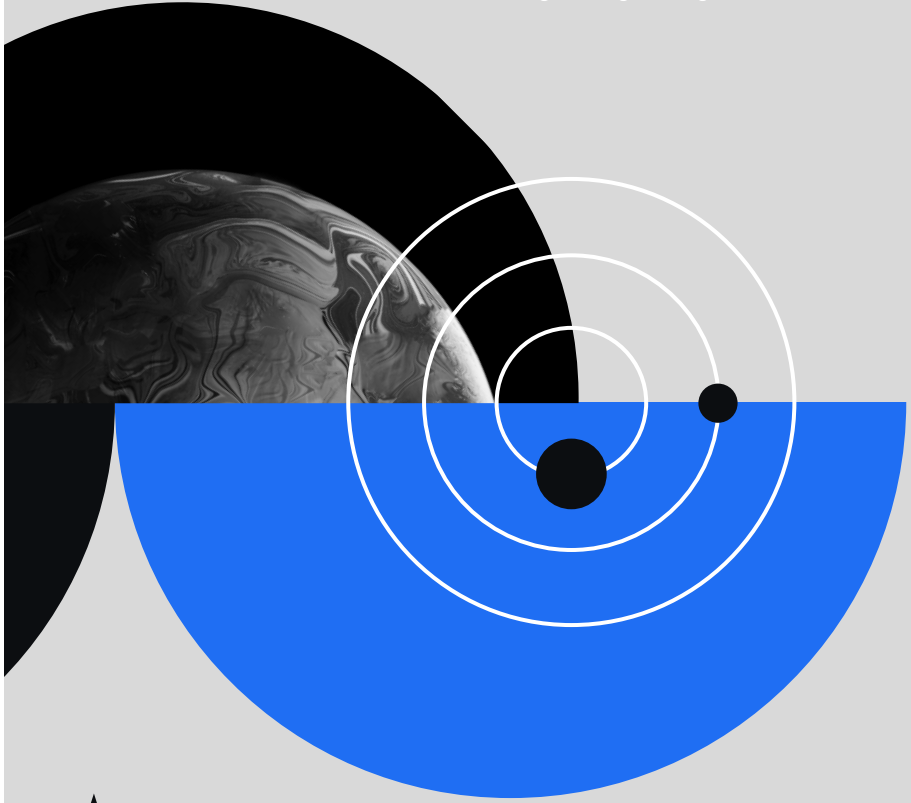

IDEAS FINALES

IDEAS FINALES

1. De problema a decisión

Partimos de un problema real de priorización: necesitamos decidir qué técnica de detección es más adecuada para cada candidato.

2. Valor tangible

El valor para vosotros es reducir incertidumbre y tiempo perdido.

3. Rigor y confianza

Aplicamos un proceso completo y reproducible.

4. Transparencia sobre limitaciones

Sabemos dónde el modelo falla: las clases minoritarias son el punto débil por falta de ejemplos.

5. Plan de mejora concreto

Los próximos pasos están definidos y son viables.

6. Camino a “producto”

Con este pipeline podemos pasar de notebook a herramienta.

GRACIAS POR SU ATENCIÓN